
Détection d'animaux camouflés par information temporelle et modèles Vision-Langage

Mounir Ammam
Université de Montréal
mounir.ammam@umontreal.ca

Byungsuk Min
Université de Montréal
byungsuk.min@umontreal.ca

Yanis Chikhar
Université de Montréal
yanis.chikhar@umontreal.ca

1 Méthodes et Résultats préliminaires

1.1 Description des méthodes développées

La composante Vision-Langage du projet est développée en trois variantes pour la détection d'animaux camouflés dans MoCA. La première approche (V1) évalue une méthode simple de reconnaissance d'images à l'aide de ResNet18, un modèle pré-entraîné pour la reconnaissance d'animaux puis adapté à MoCA avec 29 images par animal ; elle prend une image en entrée et retourne l'animal détecté. La deuxième approche (V2) reprend la même base de reconnaissance avec ResNet, mais l'étend à une séquence d'images : le modèle est entraîné sur 30 images par animal, prédit l'animal sur chaque image, puis applique un vote majoritaire pour produire la prédiction finale. Enfin, la troisième approche (V4) introduit une dimension temporelle plus explicite avec une méthode *Vision-Langage* fondée sur OWL-ViT : elle combine une inférence au niveau des frames, un filtrage des boîtes candidates (top-k et contrôle de taille), un raffinement temporel basé sur la cohérence inter-frames, puis un suivi par IoU avec agrégation afin de générer une sortie au niveau de la trajectoire.

1.2 Changements pertinents par rapport au plan initial

Le plan initial a globalement été respecté pour l'ensemble des composantes. Pour V1 et V2, aucune modification majeure n'a été nécessaire et la métrique d'exactitude sera discutée ultérieurement. Concernant V4, l'accent a été mis sur la mise en place d'une chaîne complète et reproductible couvrant l'inférence, le raffinement temporel, le suivi et la visualisation afin de permettre une comparaison rigoureuse entre méthodes. Des ajustements pratiques ont également été introduits — notamment la sélection top-k, la pénalisation des grandes surfaces et l'intégration de contraintes de cohérence temporelle — afin de réduire les boîtes trop larges et de stabiliser les détections.

1.3 Résultats préliminaires

Les résultats montrent que la fonction de coût utilisée, l'entropie croisée, atteint 0.0267 pour V1 et 0.0485 pour V2. L'exactitude, définie comme la proportion de prédictions correctes, est respectivement de 0.993 et 1.0. D'autres métriques seront intégrées ultérieurement pour une évaluation plus complète. Pour V4, une évaluation préliminaire a été menée sur cinq vidéos MoCA. Les métriques retenues incluent AP@0.5, la précision, le rappel et le score F1, afin d'évaluer la qualité globale de détection et le compromis précision-rappel. Aucun tableau chiffré final n'est encore présenté, le protocole d'évaluation étant en cours de consolidation.

31 **Exemples qualitatifs.** La Figure 1 montre un exemple correct et un exemple non-correct de
32 détection V4.



Figure 1: Exemples qualitatifs V4: à gauche un cas correct, à droite un cas non-correct avec boîte trop large.

33 Les erreurs observées sont surtout des *sur-localisations* (boîtes trop larges), ce qui réduit l’IoU
34 et pénalise surtout le rappel et l’AP@0.5. Globalement, la méthode est opérationnelle, mais sa
35 robustesse reste variable selon les scènes.

36 1.4 Défis

37 Les principaux défis concernaient la séparation du jeu de données et l’entraînement du modèle.
38 L’apprentissage s’est globalement bien déroulé dès les premières tentatives, sans ajustements majeurs
39 des hyperparamètres, et les résultats sont conformes aux attentes, bien que les métriques actuelles
40 puissent être optimistes. Le temps d’entraînement reste toutefois long sur CPU, ce qui motive une
41 optimisation future. Concernant V4, les difficultés portent surtout sur la localisation, avec des boîtes
42 parfois trop larges et une sensibilité à certains hyperparamètres. Le choix des métriques et seuils
43 d’évaluation influence fortement l’interprétation des performances, qui varient selon les scènes et le
44 degré de camouflage, confirmant l’hétérogénéité du jeu de données MoCA.

45 1.5 Description des méthodes prévues

46 Les travaux à venir portent principalement sur l’optimisation de l’entraînement et l’évaluation avec
47 des métriques complémentaires. À ce stade, V1 et V2 offrent des performances satisfaisantes, mais
48 nécessitent une optimisation de la procédure d’entraînement. La composante V3 correspond à
49 l’intégration d’un module *Vision–Language* au pipeline classique (V1/V2) afin de reclasser ou filtrer
50 les détections candidates à l’aide de prompts sémantiques, puis d’en mesurer l’impact sur les mêmes
51 métriques (AP@0.5, précision, rappel, F1). La comparaison finale inter-méthodes n’ayant pas encore
52 été réalisée, les prochaines étapes consistent à effectuer une évaluation standardisée entre V1, V2,
53 V3 et V4, ainsi qu’à affiner la composante V4 par *fine-tuning* avant une comparaison avec la version
54 zero-shot.